BRIEF PROJET / DATA ANALYST

PRÉDIRE LES ANNULATIONS DE RÉSERVATIONS HÔTELIÈRES

FORMAT	PÉRIODE	SOUTENANCE
Équipes de 3	**26 au 30 octobre 2026**	**Vendredi matin**

01 Contexte

Un groupe hôtelier exploite deux établissements aux profils distincts. Les annulations de réservations compliquent la prévision de l'occupation, l'organisation des équipes et le pilotage commercial.

La direction souhaite s'appuyer sur ses données historiques pour mieux comprendre les annulations et anticiper les réservations les plus exposées à ce risque.

02 Problématique

Dans quelle mesure les données disponibles lors d'une réservation permettent-elles d'anticiper son annulation, et comment transformer cette prédiction en décision métier ?

03 Mission

Votre équipe intervient comme une cellule Data Analyst chargée de produire un diagnostic fondé sur les données, une analyse SQL exploitable et un modèle de classification. Le travail devra aboutir à des recommandations argumentées pour les responsables des établissements.

DONNÉES DE TRAVAIL

Hotel Booking Demand — 119 390 réservations, 32 variables, deux types d’hôtels ; arrivées entre juillet 2015 et août 2017. Variable à prédire : **is_canceled**.

Fichier : **hotel_bookings.csv** | Source : **Kaggle – Hotel Booking Demand**

Travaux attendus

01 Python / Exploration et préparation

- Présenter la structure du jeu de données, sa qualité et les choix effectués sur les données.
- Produire des analyses descriptives et des visualisations qui répondent à des questions liées aux annulations.
- Formuler des constats chiffrés et comparer les situations des deux établissements.

02 SQL / Analyse de l'activité

- Intégrer les données dans une base SQL exploitable.
- Présenter au moins **6 requêtes SQL** répondant à des questions métier sur les réservations, les annulations et les segments de clientèle.
- Mobiliser des regroupements, des agrégations et au moins une construction SQL avancée (CTE, sous-requête ou fonction de fenêtrage).
- Accompagner chaque résultat d'une interprétation utile à la direction.

03 Machine Learning / Classification

- Définir précisément le moment auquel la prédiction serait utilisée et retenir des variables compatibles avec cet usage.
- Construire et comparer au moins **3 modèles de classification**, dont une régression logistique.
- Présenter une évaluation fiable et justifier les métriques ainsi que le choix du modèle retenu.
- Expliquer les limites du modèle, les erreurs de prédiction et les conséquences possibles pour l'activité.

04 Décision / Recommandations

La direction peut intervenir de manière proactive sur **100 réservations parmi 1 000 réservations à venir**. Proposez une règle de priorisation fondée sur vos résultats, justifiez-la et précisez ses limites. Les recommandations doivent être cohérentes avec vos analyses et vos prédictions.

MODALITÉS DE RENDU

Livrables et soutenance

01 Livrables collectifs

Chaque groupe remet un **dépôt GitHub unique**, organisé et reproductible, comprenant :

- Les notebooks ou scripts Python d'exploration, de préparation et de classification.
- Les requêtes SQL ainsi que les éléments nécessaires à la création et au chargement de la base.
- Un fichier **README.md** présentant le projet, les choix, les principaux résultats et les modalités d'exécution.
- Une **synthèse métier de deux pages maximum** reprenant les constats, la comparaison des modèles et les recommandations.
- Un support de présentation destiné à la soutenance.

02 Soutenance / Vendredi 30 octobre 2026

- **12 minutes** de présentation par équipe, suivies de **5 minutes** d'échanges.
- Les trois membres du groupe participent à la présentation.
- Les questions peuvent porter sur l'ensemble du projet, quel que soit le partage des travaux au sein de l'équipe.

03 Attentes transversales

Le rendu sera apprécié sur la pertinence des analyses, la maîtrise des outils Python et SQL, la rigueur de l'évaluation des modèles, la qualité des décisions proposées et la capacité de l'équipe à défendre ses choix. L'organisation du travail est laissée à l'initiative de chaque groupe.

RÉFÉRENCES DES DONNÉES

Jeu de données : Hotel Booking Demand (Kaggle). Publication source : N. António, A. de Almeida et L. Nunes, *Hotel booking demand datasets*, Data in Brief, 2019. DOI : 10.1016/j.dib.2018.11.126.