Prédire les annulations de réservations hôtelières

Projet Data Analyst · Simplon Lyon · Soutenance du 30 octobre 2026

Brice · Mouna · Zohair

Peut-on anticiper une annulation dès la réservation ?

La question de la direction

Dans quelle mesure les données disponibles lors d'une réservation permettent-elles d'anticiper son annulation, et comment en faire une décision métier ?

Contrainte : agir sur 100 réservations parmi 1 000 à venir

Le contexte

Un groupe hôtelier, deux établissements aux profils distincts : un City Hotel et un Resort Hotel

Le problème

Les annulations compliquent la prévision de l'occupation, l'organisation des équipes et le pilotage commercial

Les données

Hotel Booking Demand (Kaggle) : 119 390 réservations, 32 variables. Variable à prédire : is_canceled

Notre démarche, en 4 étapes

Période d'analyse : arrivées de juillet 2015 à août 2017

1 Explorer et préparer → **2 Comprendre** → **3 Prédire** → **4 Décider**

Python · EDA

Structure et qualité des données, nettoyage, visualisations, constats chiffrés

SQL

Base SQLite interrogée avec DBeaver : 7 requêtes métier, CTE, RANK, LAG, sous-requête

Machine learning

Prédiction le jour de la réservation : 3 modèles comparés et réglés

Recommandations

Règle de priorisation des 100 réservations sur 1 000

Un quart des lignes étaient des doublons

119 390 → 87 208
réservations avant et après nettoyage (2015-2017)

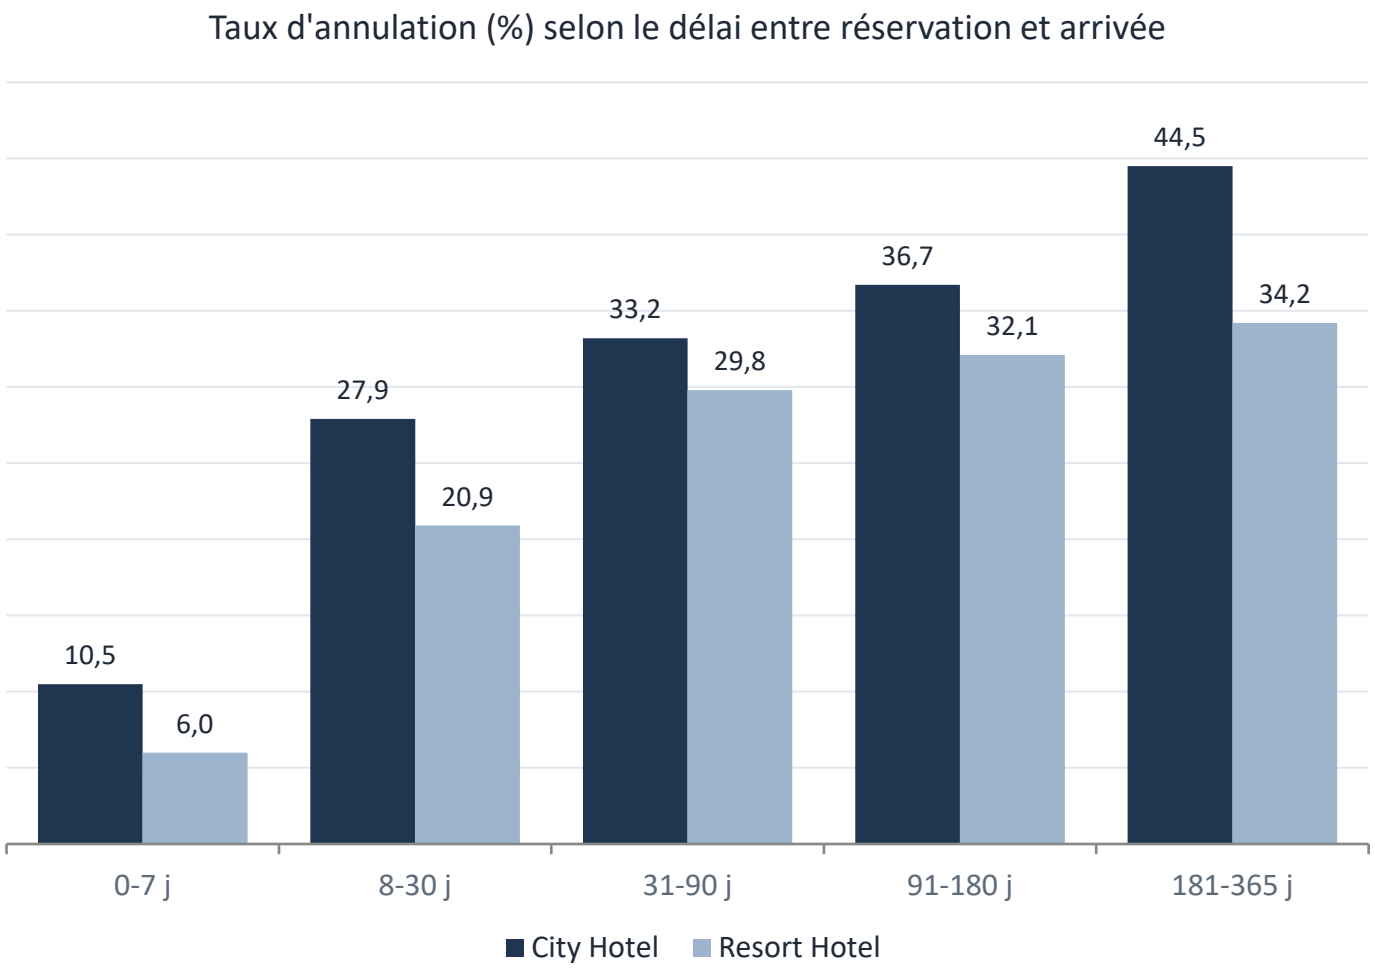
37,0 % → 27,5 %
taux d'annulation avant et après

53 267 / 33 941
réservations City Hotel / Resort Hotel

Problème	Ce qu'on a constaté	Décision
Doublons exacts	31 994 lignes (26,8 %), annulées à 63 %	Supprimés
Valeurs manquantes	company vide à 94 %, agent 14 %, country 0,4 %, children 4 lignes	company supprimée ; agent → 0, country → « Unknown », children → 0
Réservations sans client	166 réservations (0 adulte, 0 enfant, 0 bébé)	Supprimées
Prix aberrants	−6,38 € et 5 400 € (le prix suivant est à 510 €)	Supprimés
Effectifs aberrants	12 blocs de plus de 10 adultes (prix 0, tous annulés) ; 3 lignes à 9-10 enfants ou bébés	Supprimés
Catégories « Undefined »	5 réservations (segment ou canal) ; repas « Undefined » = « SC »	Supprimées ; repas regroupé
Prix à 0, séjours de 0 nuit	1 778 et 651 réservations plausibles (séjours offerts, à la journée)	**Gardés**

Contrôle croisé : le même nettoyage refait en SQL donne exactement 87 208 réservations.

Plus on réserve tôt, plus on annule



30,1 % vs 23,5 %

Taux d'annulation 2015-2017 : le City Hotel annule plus que le Resort Hotel

36,1 % / 33,8 %

Online TA (agences en ligne) : le segment qui annule le plus, City / Resort

94,7 %

Acompte non remboursable : cas à part (1 037 réservations, surtout des groupes et des agences hors ligne)

SQL : un tiers du chiffre d'affaires réservé est annulé

Base SQLite reproductible

- create_load.py charge le CSV brut
- Requêtes exécutées dans DBeaver
- Vue bookings : nettoyage en SQL, 87 208 lignes
- 7 requêtes métier commentées (R1 à R7)
- Constructions avancées : CTE, RANK(), LAG(), sous-requête

R4

11,5 M€

de chiffre d'affaires annulé sur 34,4 M€ réservés (35,2 % au City, 31,0 % au Resort). Les réservations annulées valent plus que la moyenne.

R7

68,7 %

d'annulations chez les clients ayant déjà annulé (City), contre 5,1 % chez les clients fidèles.

R6

+1,7 à +16,6 pts

chaque mois vs le même mois de l'année précédente, dès août 2016 (City) : la hausse est réelle, pas saisonnière.

Ne donner au modèle que ce qu'on sait à la réservation

18 variables gardées

10 variables numériques:

- Délai de réservation (lead_time), nuits, adultes, enfants, bébés
- Historique : client fidèle, annulations passées, réservations honorées
- Prix moyen par nuit (adr)

8 variables catégorielles:

- Hôtel, mois d'arrivée, formule repas, chambre réservée
- Segment, canal de vente, type d'acompte, type de client

Variables exclues (inconnues ou non fiables)

reservation_status, sa date

→ contiennent la réponse (fuite de données)

assigned_room_type, booking_changes, days_in_waiting_list

→ connues après la réservation

total_of_special_requests, required_car_parking_spaces

→ ajoutables après coup

country

→ souvent complété à l'arrivée

agent, company

→ identifiants, pas des quantités

L'accuracy est trompeuse : on juge sur l'AUC

Encodage des variables catégorielles
18 → 55 colonnes

Découpage
80 % / 20 %
Stratifié
(même taux d'annulation dans chaque groupe)

Standardisation
(mise à l'échelle)

3 modèles
+ référence

Évaluation
sur le test
(17 442)

Modèle de référence (DummyClassifier)

Répondre « non annulée » à tout le monde :

72,5 %

d'accuracy, sans détecter une seule annulation

0,5

d'AUC : aucune capacité à classer

Pourquoi l'AUC ?

- Classes déséquilibrées : 27,5 % d'annulations
- La direction veut classer les réservations par risque pour choisir les 100 premières
- L'AUC mesure justement la qualité de ce classement (0,5 = hasard, 1 = parfait)

Le Random Forest obtient la meilleure AUC

Modèle	Accuracy	Précision	Rappel	F1	AUC
Référence (DummyClassifier)	0,725	–	–	–	0,500
Régression logistique	0,754	0,681	0,202	0,311	0,748
Arbre de décision (profondeur 5)	0,746	0,984	0,079	0,147	0,749
Random Forest (profondeur 10)	**0,751**	**0,902**	**0,108**	**0,192**	**0,776**

Accuracy

75 % contre 72,5 % pour la référence : un progrès faible, qui ne dit presque rien

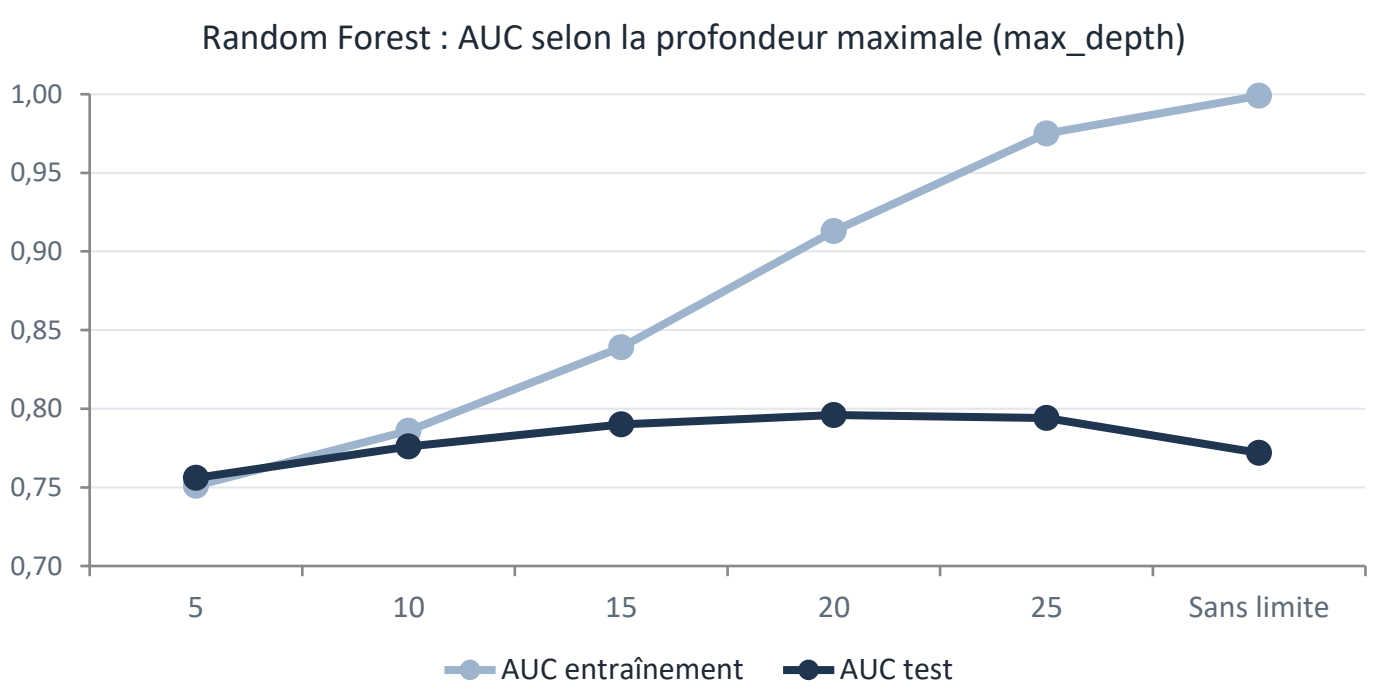
Rappel

Les modèles sont très prudents : le Random Forest ne détecte que 11 % des annulations

AUC

Tous classent bien mieux que le hasard. Le Random Forest classe le mieux (0,776)

Améliorer les modèles : régler sans surapprendre



max_depth	5	10	15	20	25	Sans limite
AUC entraînement	0,751	0,786	0,839	0,913	0,975	0,999
AUC test	0,756	0,776	0,790	**0,796**	0,794	0,772

Ce qu'on a testé

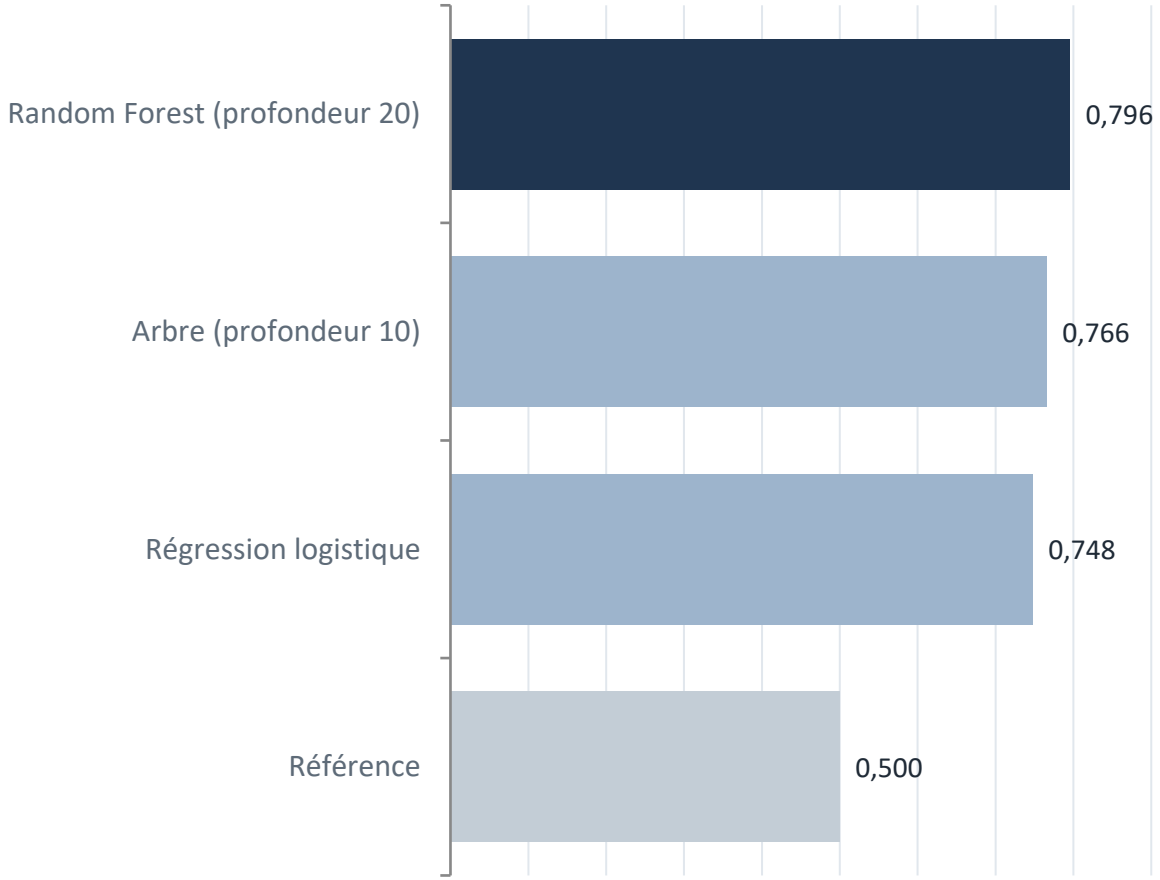
- Random Forest : max_depth de 5 à sans limite → 20
- Arbre : max_depth de 3 à sans limite → 10
- Régression logistique : C de 0,01 à 100 → aucun effet

Surapprentissage visible

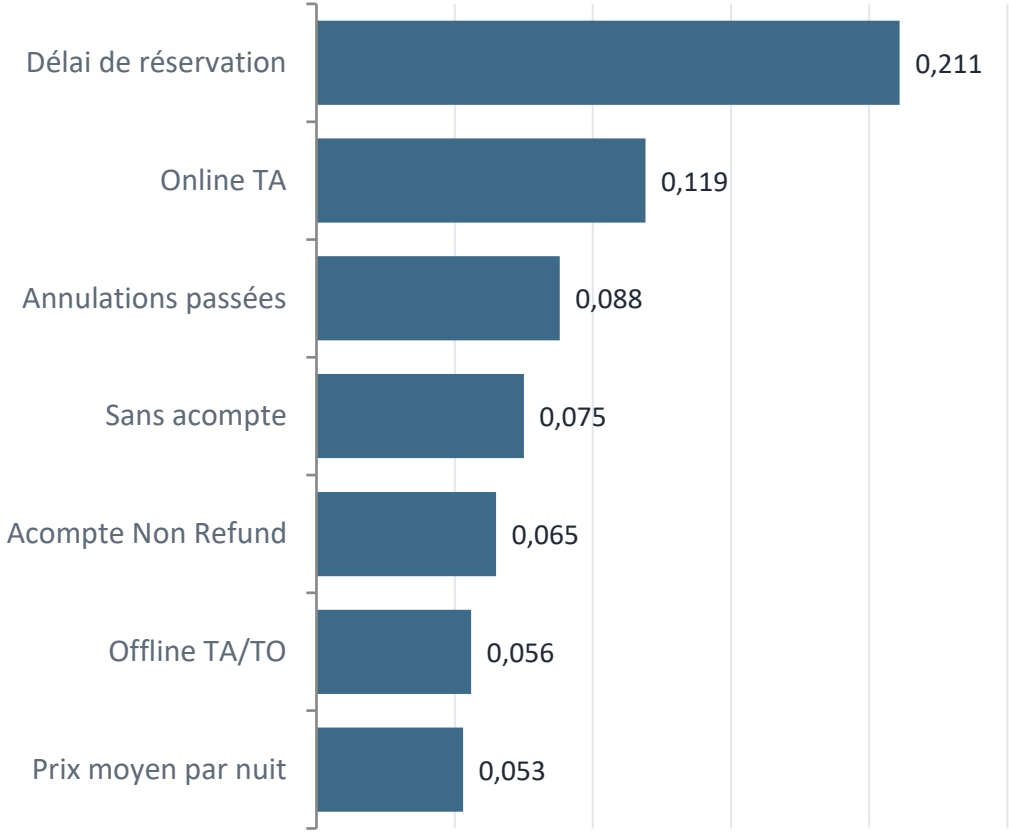
Sans limite, la forêt atteint 0,999 en entraînement mais retombe à 0,772 en test.

Modèle retenu : Random Forest, AUC de 0,796

AUC sur le test après réglage



Variables les plus influentes (Random Forest, profondeur 10)



Le modèle retenu résiste aux vérifications

1. Changer le hasard de la forêt

Même découpage, seul le random_state de la forêt change

random_state	AUC test	Top 100 sans Non Refund
15	0,7968	72
42 (rendu)	**0,7963**	**68**
100	0,7962	70

L'AUC ne bouge presque pas : le résultat ne dépend pas d'un tirage chanceux.

2. Optimisation complète (GridSearchCV)

12 combinaisons, validation croisée sur l'entraînement seul

Réglage	AUC validation	AUC test
Meilleur : profondeur 20, 200 arbres	0,7881	0,7969
Retenu : profondeur 20, 100 arbres	**0,7869**	**0,7963**

Testés : profondeur 15, 20, 25 · 100 ou 200 arbres · min_samples_leaf 1 ou 5

La profondeur 20 est confirmée. Doubler le nombre d'arbres n'apporte presque rien : on garde le modèle actuel, plus rapide.

Conclusion : ni le hasard ni d'autres réglages ne changent le résultat. AUC stable autour de 0,796.

Erreurs, limites et conséquences pour l'hôtel

Random Forest final (test : 17 442 réservations)

	Prédit : non annulée	Prédit : annulée
Réel : honorée	**Vrais négatifs** **12 154** Honorées, bien prévues	**Faux positifs** **490** Fausse alerte : client contacté inutilement
Réel : annulée	**Faux négatifs** **3 560** Annulation ratée : chambre vide imprévue	**Vrais positifs** **1 238** Annulation bien détectée

Précision 0,716 · Rappel 0,258 : le modèle sert à classer, pas à prédire toutes les annulations

Limites

- Découpage aléatoire : un découpage chronologique serait plus réaliste, car les annulations augmentent dans le temps
- Données 2015-2017, deux hôtels portugais : les comportements ont pu changer
- On ne sait pas si un appel empêche vraiment l'annulation : à tester sur le terrain
- Cas à part des acomptes non remboursables (94,7 % d'annulations), appris par le modèle
- Montants estimés (prix × nuits), sans les chambres revendues

De la prédiction à la décision

Exemple illustratif : 5 réservations, 2 appels possibles

Réservation	Risque prédit	Acompte	Décision
A	Très élevé	Non remboursable	Écartée : argent déjà gardé
B	Élevé	Sans acompte	**Contactée (1re)**
C	Assez élevé	Sans acompte	**Contactée (2e)**
D	Faible	Sans acompte	Pas contactée
E	Très faible	Sans acompte	Pas contactée

1. Prédire

Qui risque d'annuler ?

Le modèle donne une probabilité d'annulation à chacune des 1 000 réservations.

2. Décider

Qui contacter avec 100 appels ?

On trie par risque, on écarte les acomptes non remboursables, on garde les 100 premières.

Les 100 réservations ciblées annulent 2,3 fois plus

Moyenne du lot

29,0 %

taux d'annulation moyen du lot (hors Non Refund)

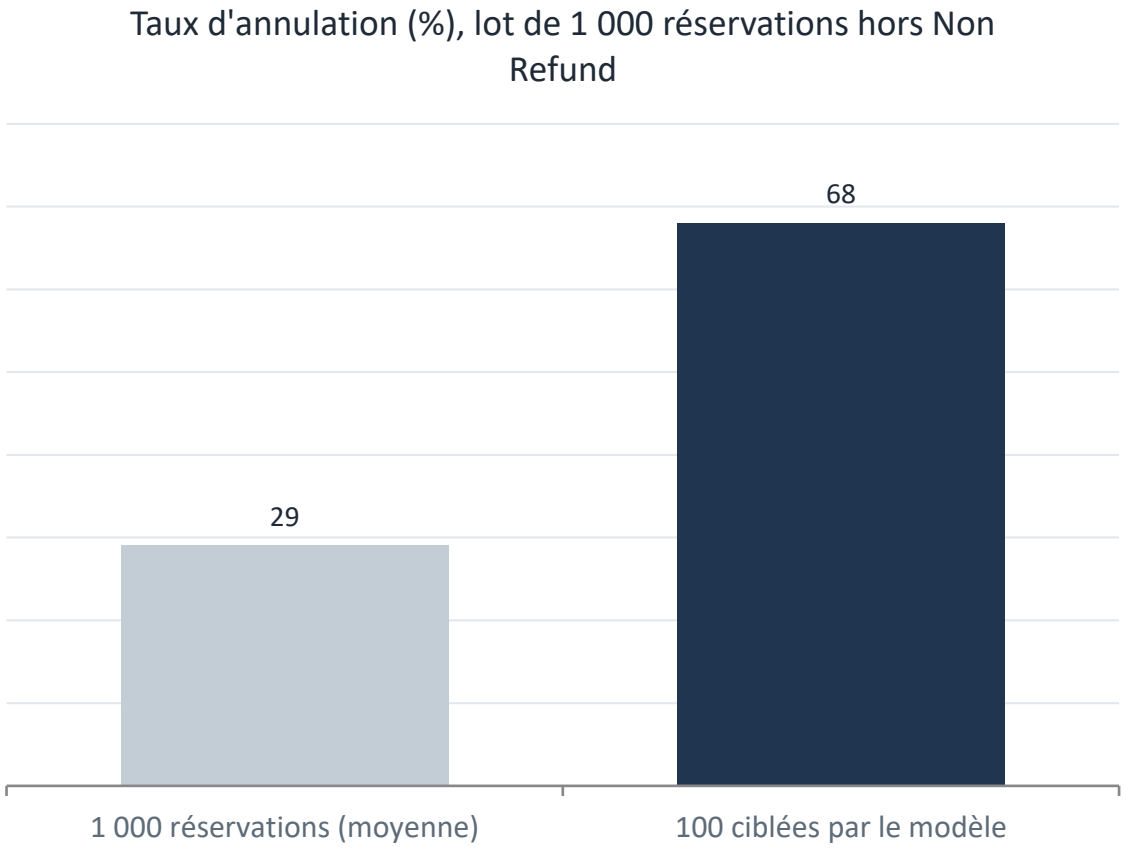
100 ciblées

68 %

des 100 réservations ciblées annulées (75 % avec les Non Refund)

71,6 %

d'annulations dans les 10 % les plus risqués de tout le test (1 744 réservations), contre 27,5 % en moyenne



Stabilité : de 54 % à 69 % sur 5 autres tirages de 1 000 réservations

Prioriser selon le chiffre d'affaires en jeu

Classement par probabilité

40,5 %

du CA annulé ciblé · 68 annulations

Probabilité × montant du séjour

49,2 %

du CA annulé ciblé · 60 annulations

Même nombre d'actions, environ 12 000 € de plus protégés sur 1 000 réservations (69 095 € contre 56 917 €)

Lien avec SQL (R4) : les réservations annulées valent plus que la moyenne. Pour la direction, l'enjeu n'est pas le nombre d'annulations mais le chiffre d'affaires perdu.

Recommandations

1. **Cibler chaque semaine** les 100 réservations à plus fort risque × valeur
2. **Sécuriser les réservations lointaines** acompte ou reconfirmation quelques semaines avant l'arrivée
3. **Surveiller les agences en ligne** et les clients ayant déjà annulé
4. **Renforcer avant l'été au Resort** toute l'année au City Hotel

Oui, le risque se prédit dès la réservation

AUC de 0,796 · les 100 réservations ciblées annulent 2,3 fois plus · jusqu'à 49 % du CA annulé ciblé

Merci. Place à vos questions.