Prédire les annulations de réservations hôtelières

Synthèse métier · Projet Data Analyst · Simplon Lyon · Soutenance du 30 octobre 2026

Question de la direction. Dans quelle mesure les données disponibles lors d'une réservation permettent-elles d'anticiper son annulation, et comment transformer cette prédiction en décision métier ? **Contrainte :** l'équipe peut agir sur 100 réservations parmi 1 000 à venir.

Périmètre. Hotel Booking Demand (Kaggle) : 119 390 réservations d'un City Hotel et d'un Resort Hotel, arrivées de juillet 2015 à août 2017. Après nettoyage (suppression de 31 994 doublons exacts et de quelques lignes incohérentes), **87 208 réservations** : 53 267 au City Hotel, 33 941 au Resort Hotel. Le taux d'annulation passe de 37,0 % à **27,5 %**. Le même nettoyage refait en SQL donne le même nombre de réservations.

1. Constats clés (exploration Python et requêtes SQL)

Constat	City Hotel	Resort Hotel	Ce que ça veut dire pour la direction
Taux d'annulation 2015-2017	30,1 %	23,5 %	Le City Hotel est le plus exposé
Délai de réservation : 0-7 j → 181-365 j	10,5 % → 44,5 %	6,0 % → 34,2 %	Plus on réserve tôt, plus on annule : le saut se fait dès 7 jours
Segment Online TA (agences en ligne)	36,1 %	33,8 %	Le segment qui annule le plus, et le plus volumineux
Clients ayant déjà annulé / clients fidèles	68,7 % / 5,1 %	66,3 % / 1,4 %	L'historique du client est un signal très fort
Part du chiffre d'affaires réservé annulé	35,2 %	31,0 %	11,5 M€ annulés sur 34,4 M€ réservés

- **La hausse des annulations est réelle :** à partir d'août 2016, chaque mois annule plus que le même mois de l'année précédente (City Hotel : +1,7 à +16,6 points). La comparaison au même mois neutralise l'effet des saisons.
- **Le Resort Hotel est très saisonnier :** 10 à 17 % d'annulations en hiver, plus de 30 % en été (37,3 % en août 2017), quand les chambres valent le plus.
- **Cas à part :** les réservations avec acompte non remboursable sont annulées à 94,7 %, mais ne représentent que 1 037 réservations, surtout des groupes et des agences hors ligne.

2. Prédiction : comparaison des modèles

Moment de la prédiction : le jour où la réservation est enregistrée. Seules les 18 variables connues à ce moment sont utilisées. Sont exclues les variables qui contiennent la réponse ou ne sont connues qu'après (statut de réservation, chambre attribuée, modifications, liste d'attente, demandes spéciales, parking, pays). Découpage : 80 % entraînement, 20 % test (17 442 réservations). **Métrique retenue : l'AUC**, qui mesure la capacité à classer les réservations par risque. L'accuracy est trompeuse : répondre « non annulée » à tout le monde donne déjà 72,5 % de bonnes réponses.

Modèle	AUC avant réglage	Meilleur réglage	AUC après réglage
Référence (DummyClassifier)	0,500	–	0,500
Régression logistique	0,748	C = 1 (aucun effet du réglage)	0,748
Arbre de décision	0,749	profondeur 10	0,766
Random Forest (retenu)	**0,776**	**profondeur 20**	**0,796**

2. Prédiction (suite) : réglage, vérifications et erreurs

- **Surapprentissage maîtrisé :** sans limite de profondeur, la forêt obtient 0,999 en entraînement mais 0,772 en test. La profondeur 20 donne le meilleur score sur des données non vues.
- **Vérifications :** changer le hasard de la forêt laisse l'AUC entre 0,7962 et 0,7968. Une optimisation complète (GridSearchCV, 12 combinaisons, validation croisée sur l'entraînement seul) confirme la profondeur 20 ; passer de 100 à 200 arbres n'apporte presque rien (0,7969 contre 0,7963 en test).
- **Variables les plus influentes :** délai de réservation, segment Online TA, annulations passées du client, type d'acompte. Elles confirment l'analyse SQL.
- **Erreurs du modèle final (test) :** 1 238 annulations détectées (vrais positifs), 3 560 annulations ratées (faux négatifs : chambres vides imprévues), 490 fausses alertes (faux positifs : clients contactés inutilement). Précision 0,716, rappel 0,258 : le modèle sert à **classer** les réservations, pas à prédire toutes les annulations.

3. Règle de priorisation : 100 réservations sur 1 000

Règle proposée. Chaque semaine : (1) calculer la probabilité d'annulation de chaque réservation à venir avec le Random Forest ; (2) écarter les réservations avec acompte non remboursable, puisque l'hôtel garde l'acompte ; (3) contacter en priorité les 100 réservations les plus risquées (reconfirmation, demande d'acompte, relance).

Résultat (jeu de test)	Réservations ciblées	Référence	Gain
Lot de 1 000 réservations, hors Non Refund	68 % annulées	29,0 % en moyenne	2,3 fois plus d'annulations touchées
10 % les plus risquées de tout le test (1 744)	71,6 % annulées	27,5 % en moyenne	Résultat confirmé sur 17 442 réservations
Variante risque × valeur (probabilité × montant du séjour)	49,2 % du CA annulé ciblé	40,5 % avec la probabilité seule	Environ 12 000 € de plus protégés sur 1 000 réservations

Stabilité : sur 5 autres tirages de 1 000 réservations, entre 54 % et 69 % des 100 réservations ciblées ont été annulées.

4. Recommandations

- **Prioriser selon le chiffre d'affaires en jeu** (risque × valeur) : avec le même nombre d'actions, on protège davantage de chiffre d'affaires. C'est le critère le plus pertinent pour le contrôle de gestion.
- **Sécuriser les réservations faites longtemps à l'avance :** acompte ou reconfirmation quelques semaines avant l'arrivée ; les réservations de dernière minute sont fiables.
- **Surveiller les agences en ligne et les clients ayant déjà annulé** (conditions d'annulation, acompte) ; fidéliser les clients réguliers, qui annulent très peu.
- **Adapter l'effort à chaque hôtel :** renforcer les actions avant l'été au Resort Hotel, toute l'année au City Hotel.

5. Limites

- Découpage aléatoire entre entraînement et test, alors que les annulations augmentent dans le temps : un découpage chronologique serait plus réaliste.
- Données de 2015 à 2017, deux hôtels portugais : les comportements ont pu changer depuis.
- On ne sait pas si un appel empêche réellement l'annulation : la règle doit être testée sur le terrain avant d'être généralisée.
- Montants estimés (prix moyen × nuits), sans tenir compte des chambres revendues après annulation ; doublons supprimés dont une partie pouvait être de vraies réservations de groupe.